

國立臺灣大學社會科學院國家發展研究所

深度學習與文字探勘專題期末報告

運用深度學習方法建立國際原油價格預測模型

109 學年度第二學期

陳鈺勳、邱廣盛

指導教授：鄧志松 博士

中華民國 110 年 6 月 10 日

一、研究動機

石油是不可再生的能源，在經濟發展中有著重要的地位。研究油價的趨勢是經濟學領域常見的議題，在預測油價的議題中，傳統計量迴歸中的 ARIMA 模型已經可以讓模型有不錯的準確度，但在深度學習崛起後漸漸開始有使用深度學習來處理時間序列資料的研究出現。使用深度學習進行預測可以避免許多傳統統計的限制。另外，由於我們只在乎模型的準確度，並不在乎變數間的因果關係，因此使用深度學習來進行預測的工作也許會有比計量迴歸模型有更好的表現，故這次的油價預測研究，本組打算蒐集過去文獻中已經被證實能夠預測油價的相關變數來訓練我們的模型，看看能否成功預測油價。

二、研究目的

油價常受到許多雜訊影響，若要進行預測則需要在模型中考量諸多面向。而過去有許多文獻都以政府定期發布之總體變數為分析點建立模型，然而隨著時代之推演，開始有更多可以解釋油價的解釋變數被發掘，且有更多傳統統計之外的建模方法。因此，本組將以過去文獻中提出的有用之變數進行模型建構，而在建模方法方面也將嘗試深度學習方法之相關文獻，嘗試 DNN、RNN-LSTM、TCN 三種深度學習模型，觀察這些模型是否能成功地預測原油價格走勢，並比較哪種模型能夠預測的更準確。

三、研究流程

研究流程方面，本組將參考過往之文獻來設計我們的模型架構以及變數選擇。資料來源以 MSCI 官方網站，以及 Yahoo 財經網站之相關網站為主，並將蒐集之變數進行清理，以增加模型的穩健性。在訓練的過程中，本組將盡可能地窮盡各種參數設定嘗試將模型進行優化，最後將訓練好的模型導入真實值後輸出預測值，最後以視覺化呈現進行結果評估後得出結論。

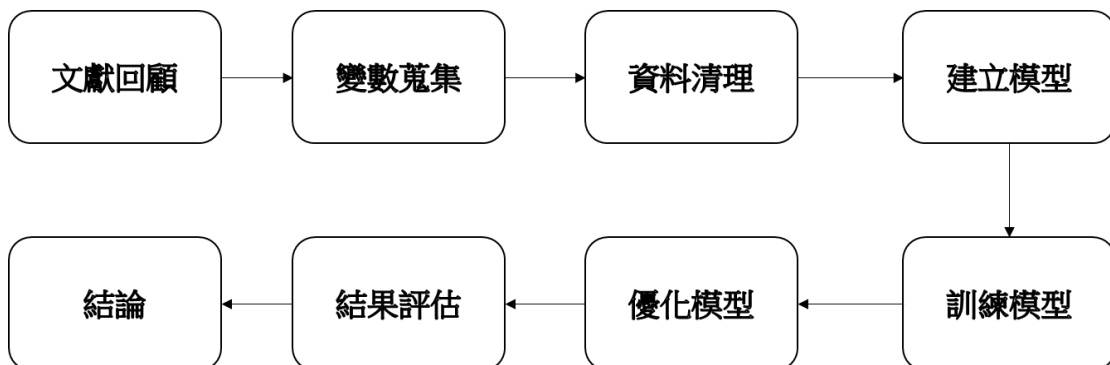


圖 1 研究流程圖

四、分析架構

4.1 研究方法

過去有關時間序列議題上，除了傳統統計以外，使用深度學習方法之學者常常會使用循環神經網絡（Recurrent Neural Networks，RNN）來訓練模型，然而自從 Shaojie Bai, J. Zico Kolter, Vladlen Koltun 於 2018 年發表了〈An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling, TCN〉這篇文章後，後續許多研究股價、匯率、期貨等各種議題的總體實證研究者都開始採用了 TCN 這種深度學習架構來做預測。由於本研究主軸為油價預測其資料型態也屬於時間序列，因此也將採用 LSTM 以及 TCN 模型來進行預測。

4.2 變數資料：

本研究之資料來源為 MSCI 官方網站，以及 Yahoo 財經網站。

資料範圍：2013/10/25 ~ 2021/4/26

樣本數：1868

使用變數：

1. 西德州中級原油：WTI 常稱為美國原油或紐約原油，代表西德州中級原油 (West Texas Intermediate)，是大宗商品交易中核心的石油基準，也是本次研究之預測標的。
2. S&P 500：美國股價之大盤指數之一，本組認為美國的大盤指數可以靈敏反映當前經濟現況，以及目前的各種風險。
3. 原油庫存：當前原油的庫存量，油價與油價的庫存量具有高度相關。
4. 布蘭特原油價格：WTI 的價格走勢往往與布蘭特原油相關，因為兩者都是輕質低硫油的基準。布蘭特原油常更廣泛被當作輕質原油市場的基準。
5. MSCI 能源 ETF 價格：根據過去文獻指出，MSCI 能源相關 ETF 價格對油價具有顯著的影響。
6. MSCI 世界能源指數：MSCI 全球指數，是摩根士丹利資本國際公司 (Morgan Stanley Capital International) 所編製的證券指數，指數類型包括產業，國家，地區等，範圍涵蓋全球，為歐美基金經理人對全球股票市場投資的重要參考指數。
7. VIX 恐慌指數：恐慌指數是反應風險的指標，相較於 S&P500 可以更全面控制原油預測模型的危機及風險。

4.2.1 資料探索

資料蒐集完成後為了進行初步的探勘，本組利用 Python3 之 Matplotlib 套件繪製各變數的走勢圖，如下圖 2。首先第一列為原油價格（WTI）之走勢圖，用以與下方其他變數做比較。另外，下方之走勢圖由左至右分別為：布蘭特原油價格、原油庫存、MSCI 能源 ETF 價格、MSCI 世界能源指數、S&P 500、VIX 恐慌指數。嘗試畫出這些變數檢視他們的相關性後發現，WTI 與能源類型的指數有高度相關。反應經濟狀態或風險的指標也有相關，但不一定是正相關。

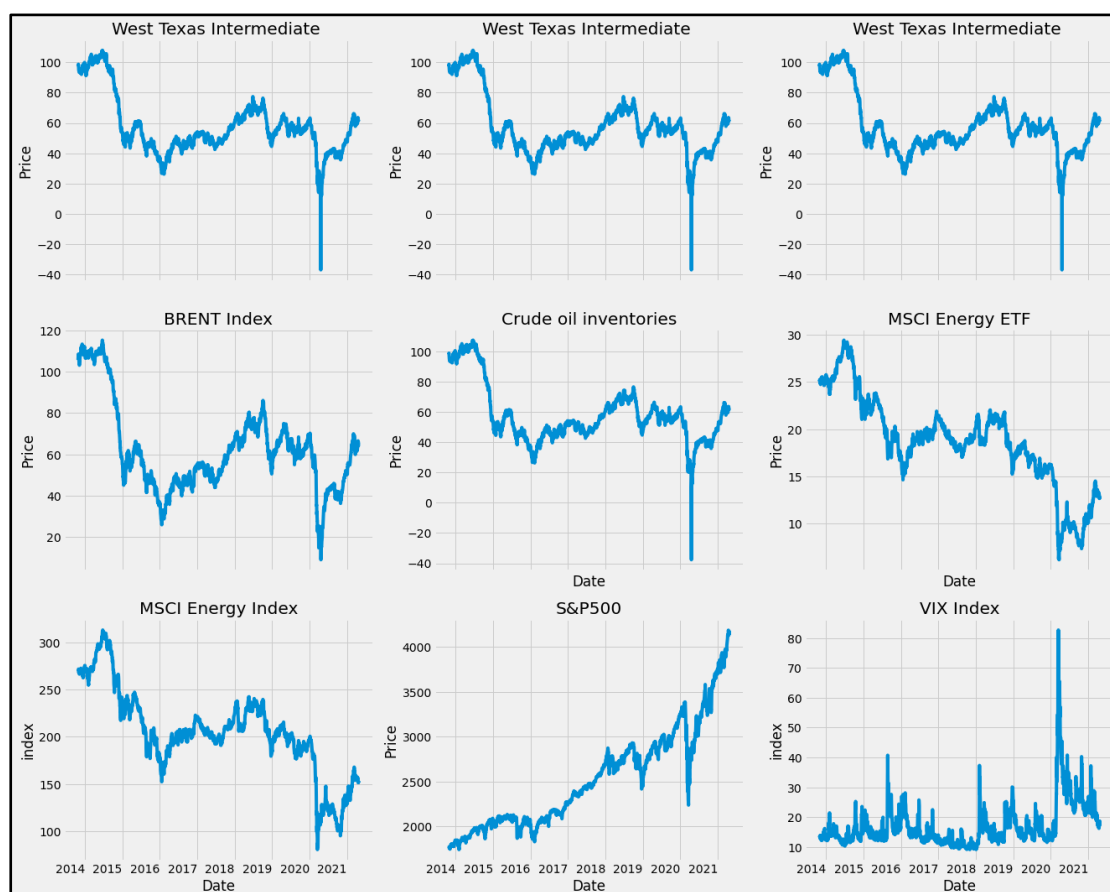


圖 2 變數走勢圖

五、訓練模型

5.1 長短期記憶模型 LSTM

長短期記憶模型 LSTM（Long Short-Term Memory，LSTM）適合處理和預測時間序列問題。LSTM 是由時間循環神經網路（RNN）（詳見，圖 3）發展而來，被描述成智慧型網路單元，可以記憶不定時間長度的數值，每個區塊之間有著決定是否記憶的閘門（Forget gate）能夠決定 input 是否重要到能被記住及

能不能被輸出 output。LSTM 還普遍用於自主語音辨識。這論文首次發表於 1997 年。

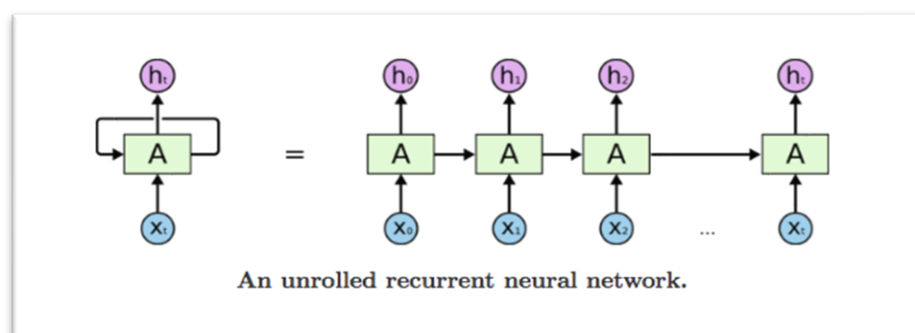


圖 3 RNN 結構圖

5.2 時間卷積網絡(TCN)

TCN，全名為 Temporal Convolution Network，時間捲積網絡(圖 4)，利用 CNN 處理時間序列資料。裡面有三種卷基層，一是一維 CNN，用來輸入資料，二個是因果卷積，可以處理時間序列的序列問題，第三個是擴張卷積，可以慢擴大卷積的範圍，增加考慮的資料量。且 CNN 有平行運算的功能，因此訓練速度也較 RNN 快。An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modelin (Shaojie Bai, J. Zico Kolter, Vladlen Koltun, 2018)提到，TCN 相較於 RNN-LSTM 有更強的記憶力，即過去的資料較不會散失，且 CNN 有平行運算的功能，因此訓練速度也較 RNN 快。




圖 4 TCN 結構圖

六、訓練成果

實驗一：

1-1 LSTM

(1) 考慮天數：60

- (2) 神經元個數：32
- (3) LSTM 層數：2
- (4). Dropout：0.01
- (5). Learning_rate：0.01
- (6). Epoch：1000
- (7) Optimizer：Adam
- (8) Loss Function：RMSE

訓練結果：




圖 5 實驗一，LSTM

1-2. TCN

- (1) 考慮天數：60
- (2) 神經元個數：32
- (3) kernel：2
- (4) Dropout：0.01
- (5) Learning_rate：0.01
- (6) Epoch：1000
- (7) Optimizer：Adam
- (8) Loss Function：RMSE

訓練結果：




圖 6 實驗一，TCN

實驗二：

2-1 LSTM

- (1) 考慮天數：5
- (2) 神經元個數：32
- (3) LSTM 層數：2
- (4). Dropout：0.01
- (5). Learning_rate：0.01
- (6). Epoch：1000
- (7) Optimizer：Adam
- (8) Loss Function：RMSE

訓練結果：




圖 7 實驗二，LSTM

2-2. TCN

- (1) 考慮天數：5
- (2) 神經元個數：32
- (3) kernel：2
- (4) Dropout：0.01
- (5) Learning_rate：0.01
- (6) Epoch：1000
- (7) Optimizer：Adam
- (8) Loss Function：RMSE

訓練結果：




圖 8 實驗二，LSTM

七、研究結論

經過這次的研究，本組有四個主要發現，首先要預測一個確切的價格，其實非常困難，因預測標的之噪音太多，模型難以控制住所有可能，但若僅僅只預測趨勢，經本研究的實驗結果則是有可能的。第二，變數增加會導致趨勢高估或低估，由於本次實驗放了許多相關性較低的變數，因此導致模型學習到了其他變數的走勢，因此導致模型低估。不過從圖 8 之結果發現，TCN 竟可以提前預測到 2020 年之最低點趨勢可以增加預測趨勢的能力，可能原因應該歸功於各種變數背後的組成導致模型學習到預測的能力。第三，Loss 僅代表模型越擬合真實值，但不代表模型越能夠預測趨勢，本次實驗也嘗試用 DNN 的模型進行測試，發現 DNN 的 Loss 最低卻沒有預測趨勢的效果，因此結果的好壞還是要由人工進行判斷。第四，考慮的天數越多不一定有更好的表現，如同 TCN 的

例子，只考慮五天反而預測了最低點。但可以看出 TCN 確實相繼於 LSTM 在時間序列議題上有更好的表現。

八、參考書目

1. (陳旭昇, 2013) Forecasting Crude Oil Price Movements with Oil-Sensitive Stocks
2. (Xuerong Lia, WeiShang ba. Shouyang Wang, 2019) Text-based crude oil price forecasting: A deep learning approach
3. (陳旭昇, 2013) 時間序列分析_總體經濟與財務金融之應用_預測表現之評估
4. (Junyoung Chung, Caglar Gulcehre, KyungHyun Cho, Yoshua Bengio, 2014) Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling
5. (Shaojie Bai, J. Zico Kolter, Vladlen Koltun, 2018) An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling